Propuesta de Proyecto: Predicción de Insatisfacción del Cliente

Información General

Concepto	Detalle
Título del Proyecto	Modelo Predictivo de Detección Temprana de Insatisfacción del Cliente
Materia	Minería de Datos
Integrantes	Vivas Escobar, Cinthia (Legajo: 18430/9) Bailon Trujillo, Carolina (Legajo: 17828/5)
Dataset	**Olist Brazilian E-Commerce Dataset** https://www.kaggle.com/code/anshumoudgil/olist-ecommerce-analytics-quasi-poisson-poly-regs
google Colab	Google Colab

1. Objetivo del Proyecto

El objetivo principal es construir y evaluar un modelo de **clasificación binaria** capaz de predecir de forma temprana la insatisfacción de los compradores a partir de las métricas de sus transacciones y tiempos de entrega.

- **Variable Objetivo (Y):** Insatisfacción del cliente.
  - **$Y = 1$ (Insatisfecho):** Puntuación de reseña (`review_score`) entre 1 y 3.
  - **$Y = 0$ (Satisfecho):** Puntuación de reseña (`review_score`) de 4 o 5.
- **Valor de Negocio:** Permitir a la plataforma identificar órdenes de alto riesgo antes o durante la entrega para tomar acciones preventivas de atención al cliente, reduciendo la tasa de desacreditación (*churn*) y optimizando los costos asociados a reclamos y devoluciones.

2. Tratamiento del Desbalance de Clases

Dado que la mayoría de los usuarios otorgan calificaciones altas (4 y 5 estrellas), la clase de interés ($Y = 1$) representa una minoría significativa. Para asegurar un aprendizaje efectivo, se implementarás las siguientes estrategias:

- **Técnicas de Remuestreo:** Evaluación comparativa de sobremuestreo sintético (**SMOTE**, **ADASYN**) y submuestreo aleatorio (*undersampling*) en el conjunto de entrenamiento.
- **Ajuste de Pesos:** Configuración del parámetro de ponderación de clases (`class_weight='balanced'`) en los algoritmos base para penalizar severamente los errores en la clase minoritaria.
- **Métricas de Evaluación:** La exactitud (*Accuracy*) será descartada por ser engañosa en datos desbalanceados. El desempeño se evaluará prioritariamente mediante **Recall** (sensibilidad para detectar insatisfechos), **F1-Score** y el área bajo la curva de Precisión-Recall (**PR-AUC**).

3. Técnicas y Algoritmos

Se desarrollará un flujo iterativo comparando modelos desde una línea base sencilla hasta arquitecturas de ensamble complejas:

1. **Regresión Logística:** Modelo baseline interprete para establecer la cota inferior de rendimiento.
2. **Árboles de Decisión y Random Forest:** Modelos no lineales para capturar interacciones complejas entre variables operativas sin asunciones de distribución.
3. **Gradient Boosting (XGBoost / LightGBM):** Algoritmos avanzados de potenciación para maximizar el rendimiento predictivo y la capacidad de generalización sobre la clase minoritaria.

4. Plan de Trabajo Resumido

El proyecto se ejecutará siguiendo las siguientes etapas clave:

Fase	Actividades Principales
1. Extracción y Feature Engineering	Consolidación de tablas relacionales de Olist y creación de variables clave: días de retraso en la entrega, costo de flete,

Fase	Actividades Principales
	distancia geográfica comprador-vendedor, e historial del vendedor.
2. Preprocesamiento y Balanceo	Limpieza de datos, imputación de nulos, codificación de variables categóricas y aplicación de técnicas de remuestreo sobre los datos de entrenamiento.
3. Entrenamiento y Tuning	Búsqueda sistemática de hiperparámetros mediante **GridSearchCV** combinada con **validación cruzada estratificada** (k-fold) para evitar la fuga de información.
4. Evaluación y Diagnóstico	Análisis comparativo de modelos mediante matrices de confusión, curvas PR y optimización del umbral de decisión (*threshold tuning*) priorizando el impacto de negocio.